Ficha 6 - Gráficos resolvida

Jorge Gustavo Rocha

May 30, 2020

1 Visualização de dados

Neste módulo vamos introduzir a biblioteca `matpoltlib` para visualização de dados.

Esta mesma biblioteca é utilizada pelo Octave para a visualização de dados.

1.1 Tabelas

Uma tabela, do tipo `pandas.DataFrame` é uma estrutura de dados multidimensional.

Vamos usar uma pequena tabela que tem os dados organizados em três colunas:

1. A primeira coluna (`'Ano'`) refere-se ao ano
2. A segunda coluna tem a correspondente taxa bruta de natalidade (`'Natalidade'`)
3. A terceira coluna tem a correspondente taxa bruta de mortalidade (`'Mortalidade'`).

Estes dados referem-se à Taxa Bruta de Natalidade e Taxa Bruta de Mortalidade. Esta taxas são calculadas para cada 1000 habitantes (dados do INE).

[1]:
```
import pandas

população = pandas.DataFrame({
    'Ano': [ 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018 ],
    'Natalidade': [ 9.2, 8.5, 7.9, 7.9, 8.3, 8.4, 8.4, 8.5 ],
    'Mortalidade': [ 9.7, 10.2, 10.2, 10.1, 10.5, 10.7, 10.7, 11.0 ]
})
```

Vamos usar esta tabela nos exemplos seguintes. Comecemos por ver a informação contida na tabela.

1.1.1 Consultar a tabela

Basta escrever `população` e é-nos apresentado o conteúdo da tabela. Esta visualização funciona bem, porque a tabela é muito pequena.

[2]:
```
população
```

[2]:

	Ano	Natalidade	Mortalidade
0	2011	9.2	9.7
1	2012	8.5	10.2
2	2013	7.9	10.2
3	2014	7.9	10.1

```
4  2015          8.3          10.5
5  2016          8.4          10.7
6  2017          8.4          10.7
7  2018          8.5          11.0
```

1.1.2 Primeiro gráfico

Vamos mostrar num gráfico os valores da Taxa Brutade Mortalidade, para cada um dos anos.

Começamos por importar a biblioteca, à qual associamos o nome `plt`.

Para o eixo dos `x`, escolhemos a coluna `Ano`. No eixo dos `y`, colocamos a taxa bruta de mortalidade.

Vamos usar um **gráfico de dispersão** `plt.scatter()`, que muitas vezes são usados como a primeira opção para visualização, para percebermos a distribuição dos dados.

[3]:
```
import matplotlib.pyplot as plt

x = população.Ano
y = população.Mortalidade
plt.scatter( x, y)
```

[3]:
```
<matplotlib.collections.PathCollection at 0x7f06d167d450>
```

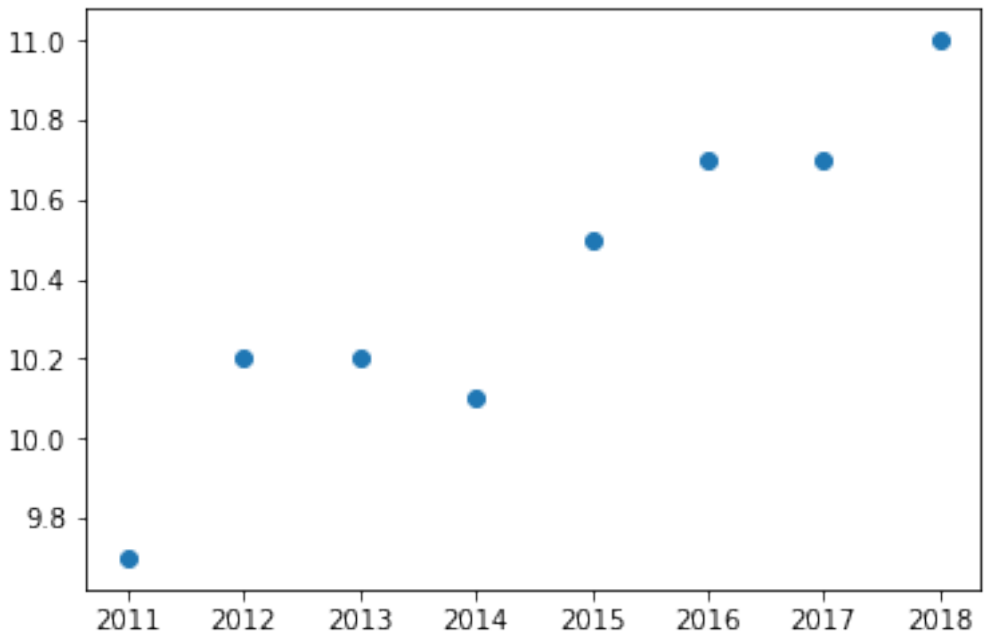

1.1.3 Exercício

Apresente o gráfico de dispersão da Taxa Bruta de Natalidade.

[4]:
```
plt.scatter( população.Ano, população.Natalidade)
```

[4]:
```
<matplotlib.collections.PathCollection at 0x7f06d0d0de10>
```

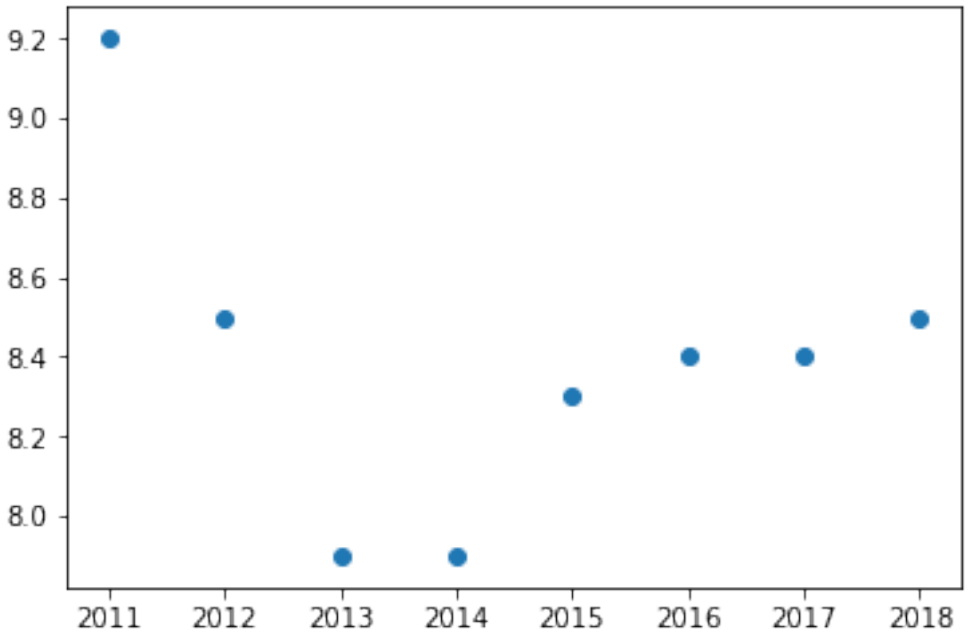

1.1.4 Tipos de gráficos

Os gráficos de dispersão são uma boa abordagem para um gráfico inicial, quando ainda não se conhecem bem os dados.

Vamos experimentar outros tipos de gráficos.

[5]:
```
plt.plot( população.Ano, população.Mortalidade)
```

[5]:
```
[<matplotlib.lines.Line2D at 0x7f06d1676b50>]
```

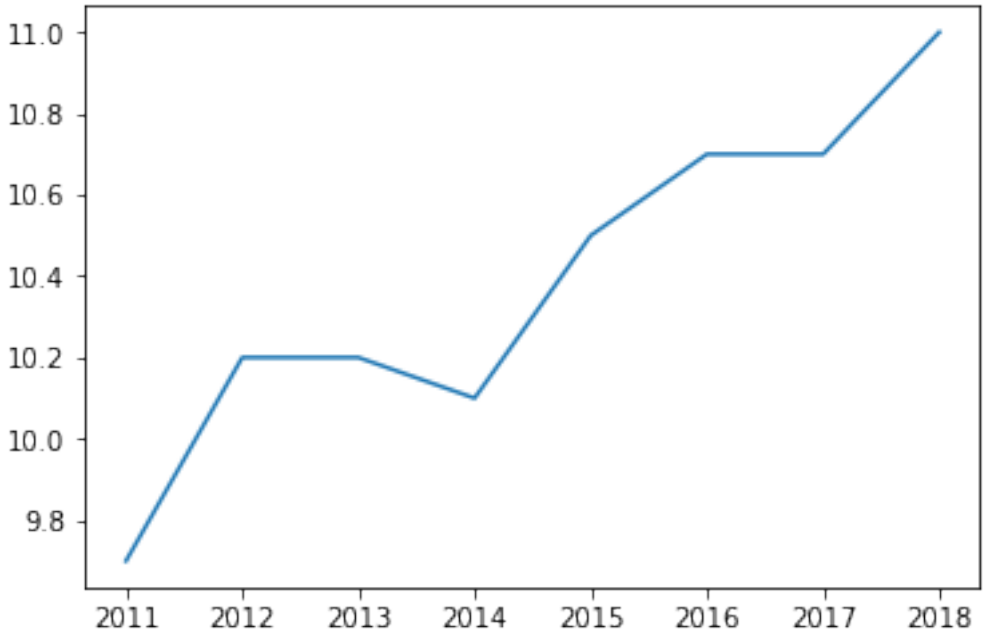

[6]:
```
plt.bar( população.Ano, população.Mortalidade)
```

[6]: <BarContainer object of 8 artists>

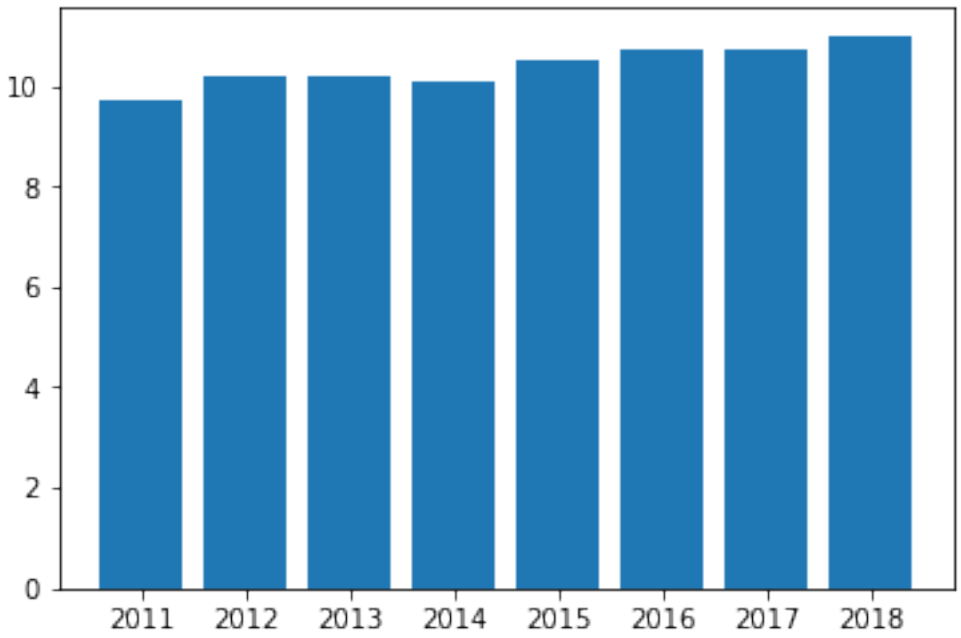

Juntando as duas séries, e adicionando uma pequena legenda.

[7]:
```
plt.bar( população.Ano-0.2, população.Natalidade, width=0.4, color="green")
plt.bar( população.Ano+0.2, população.Mortalidade, width=0.4, color="black")
plt.legend([ 'Natalidade', 'Mortalidade'], loc='lower right')
```

[7]:
```
<matplotlib.legend.Legend at 0x7f06d088d9d0>
```

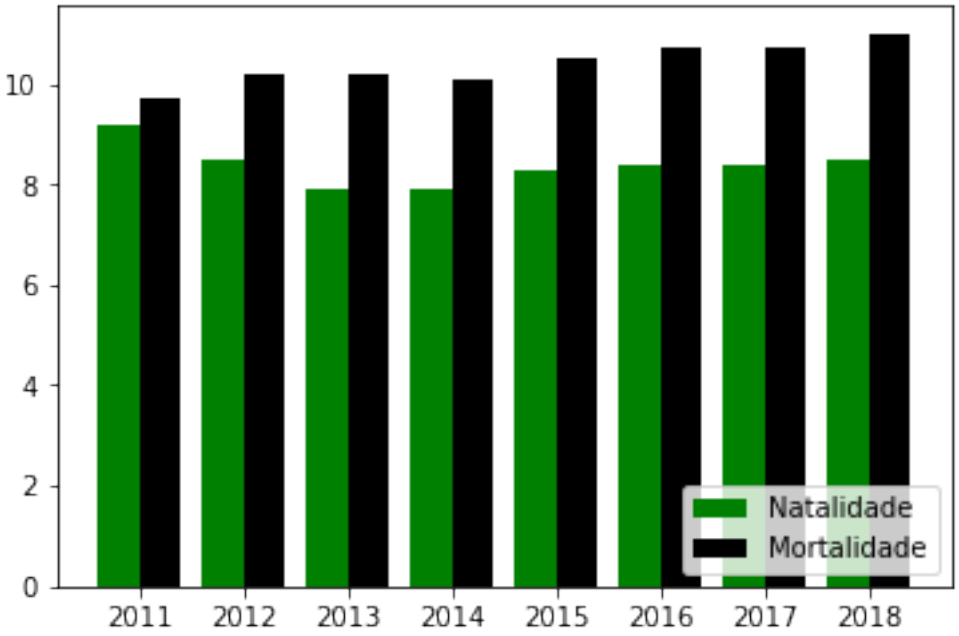

1.1.5 Estilo do gráfico

A apresentação do gráfico pode ser personalizada. A maneira mais fácil é escolher uma dos múltiplos estilos existentes.

[8]:
```
plt.style.use('dark_background')
plt.plot( população.Ano, população.Mortalidade)
```

[8]:
```
[<matplotlib.lines.Line2D at 0x7f06d08a8a50>]
```

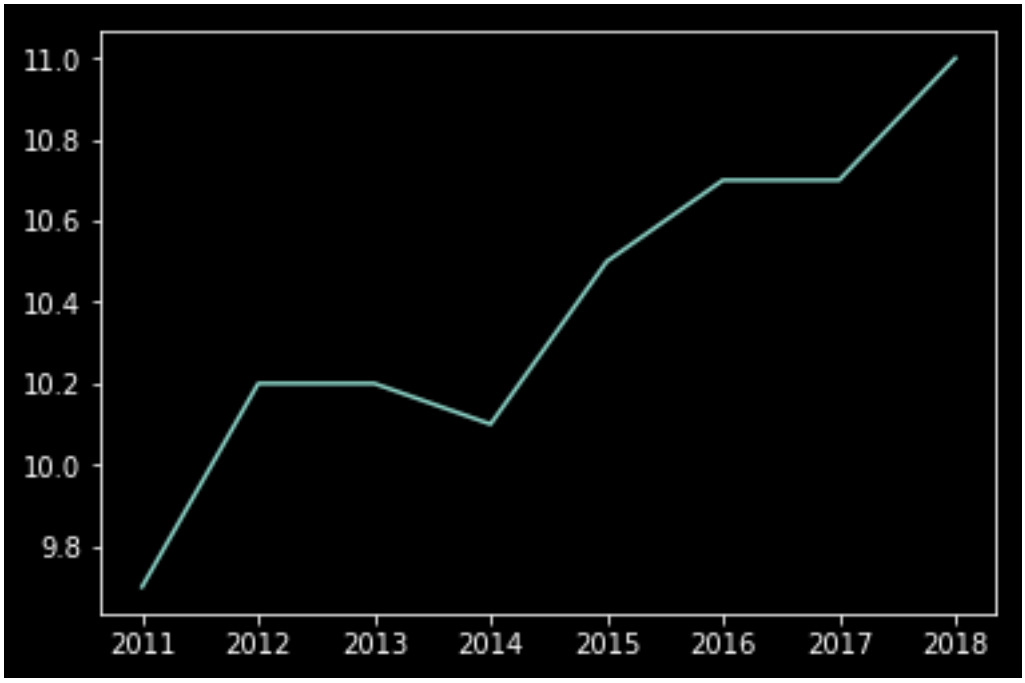

[9]:
```
plt.style.use('Solarize_Light2')
plt.plot( população.Ano, população.Mortalidade)
```

[9]: [<matplotlib.lines.Line2D at 0x7f06d0a1e950>]

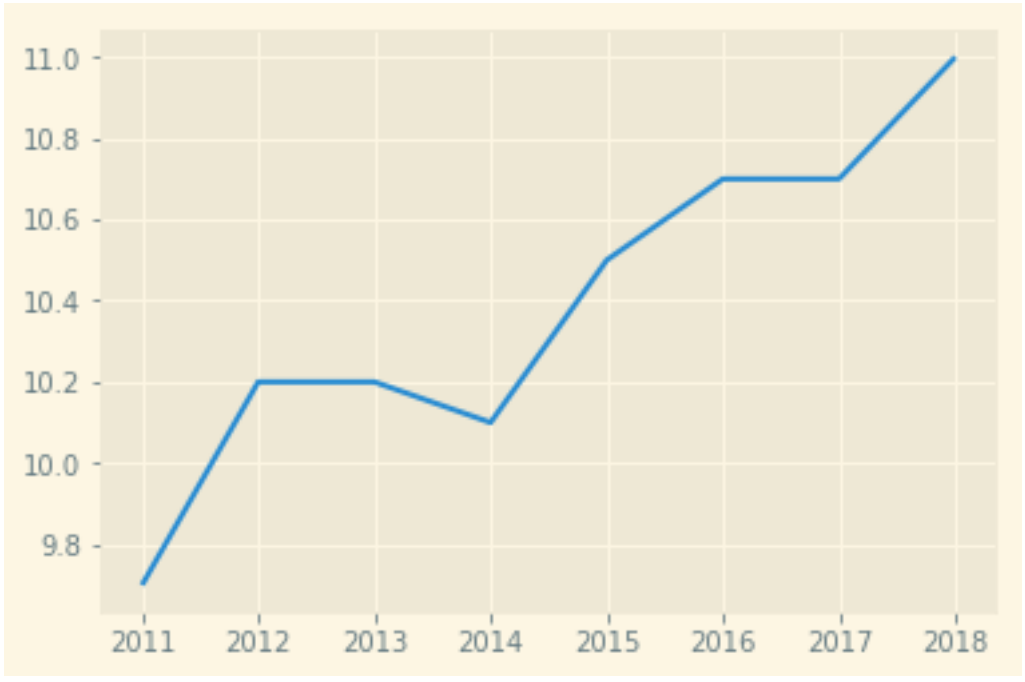

Além do estilo, existe ainda mais algumas funções que permitem alterar a forme de desenho, como este `plt.xkcd()`, que dá o mesmo efeito dos cartoons do xkcd.

[10]:
```
plt.xkcd()
plt.plot( população.Ano, população.Mortalidade)
```

[10]:
```
[<matplotlib.lines.Line2D at 0x7f06d082e2d0>]
```

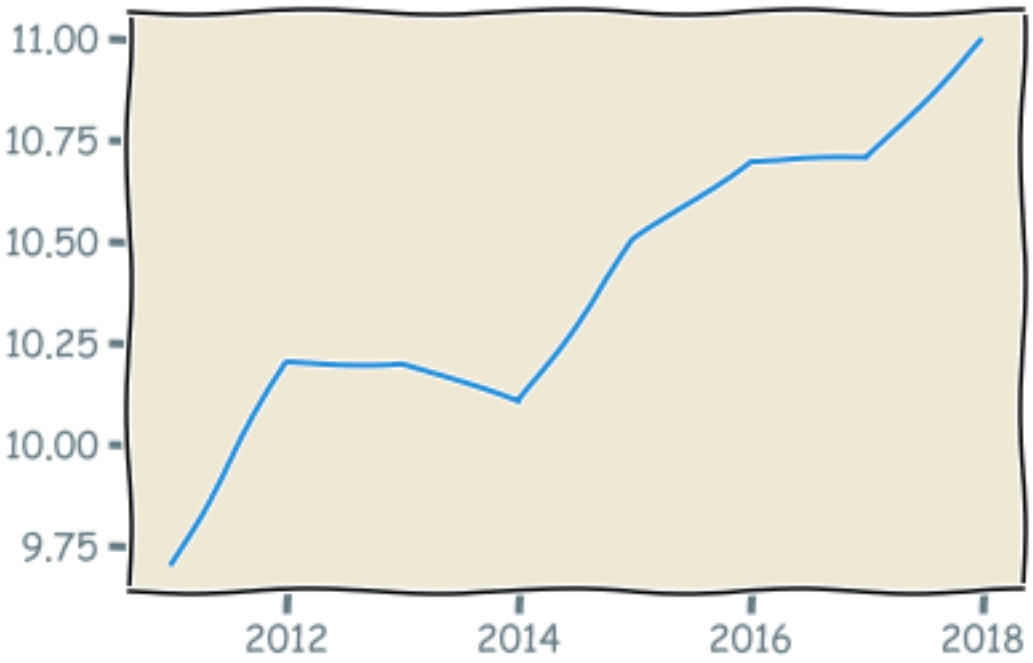

1.1.6 Exercício

Descobra um outro estilo ao seu gosto e use-o aqui, aplicado ao mesmos dados anteriores.

[ ]:
```

```

1.1.7 Estilo padrão

Para voltar ao estilo padrão, usar `plt.style.use('default')`.

[11]:
```
plt.style.use('default')
plt.plot( população.Ano, população.Mortalidade)
```

[11]:
```
[<matplotlib.lines.Line2D at 0x7f06d070aed0>]
```

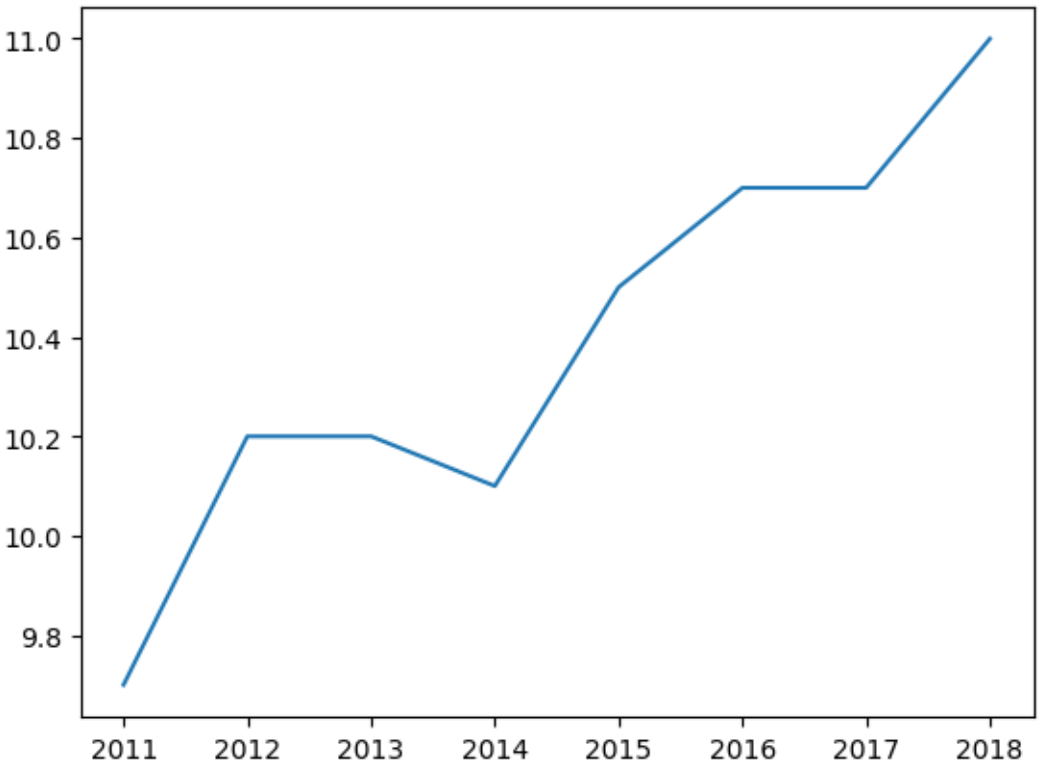

1.1.8 Gráfico de setores ou gráfico circular

Estão gráficos são muito apropriados para se perceber a proporção entre variáveis.

[12]:
```
colunas = ['Natalidade', 'Mortalidade']
valores = população[ população.Ano == 2018][ colunas ].values
plt.pie(valores[0], labels=colunas)
plt.xlabel("Taxas em 2018")
```

[12]:
```
Text(0.5, 0, 'Taxas em 2018')
```

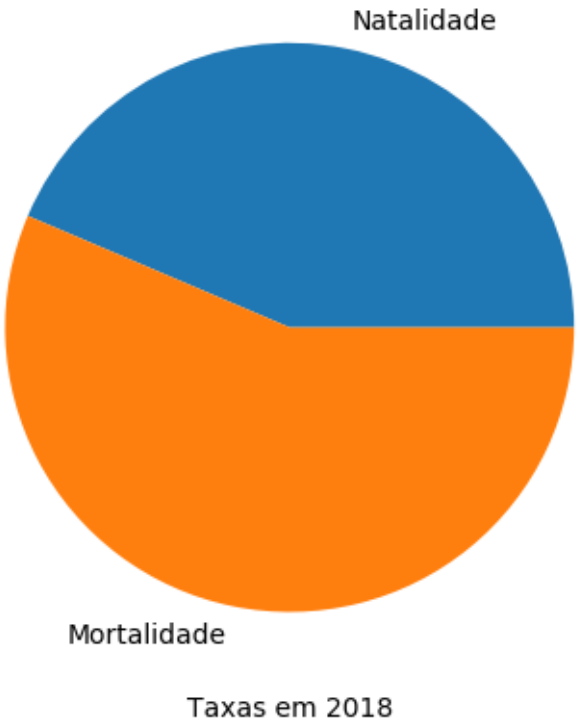

Outro exemplo. que se se usa o parâmetro `explode` para destacar um dos elementos.

[13]:
```
partidos = 'PAF', 'PS', 'BE', 'PCP+PEV', 'PAN'
deputados = [ 107, 86, 19, 17, 1 ]
# destaca o segundo elemento da lista
explode = (0, 0.1, 0, 0, 0)
plt.pie(deputados, explode=explode, labels=partidos, shadow=True)
plt.xlabel("Legislativas de 2015")
```

[13]:
```
Text(0.5, 0, 'Legislativas de 2015')
```

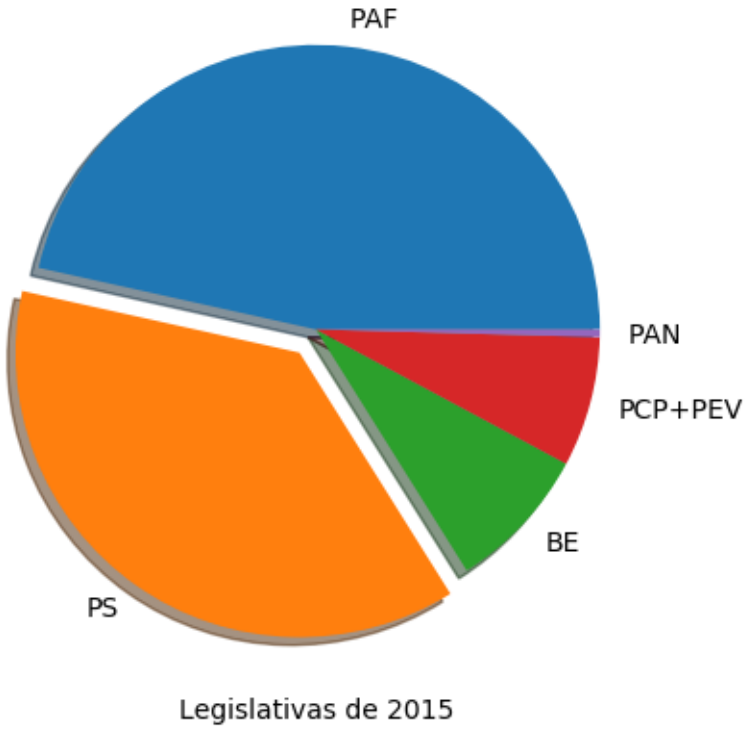

1.1.9 Exercício

Sabendo que o Sporting Clube de Braga, num temporada anterior, ao fim de 19 jogos, tinha conseguido:

```
11 vitórias,
3 empates,
5 derrotas.
```

Faça um gráfico de setores que represente a proporção entre vitórias, empates e derrotas.

Tente fazer um gráfico o mais semelhante possível com o que foi feito no Octave.

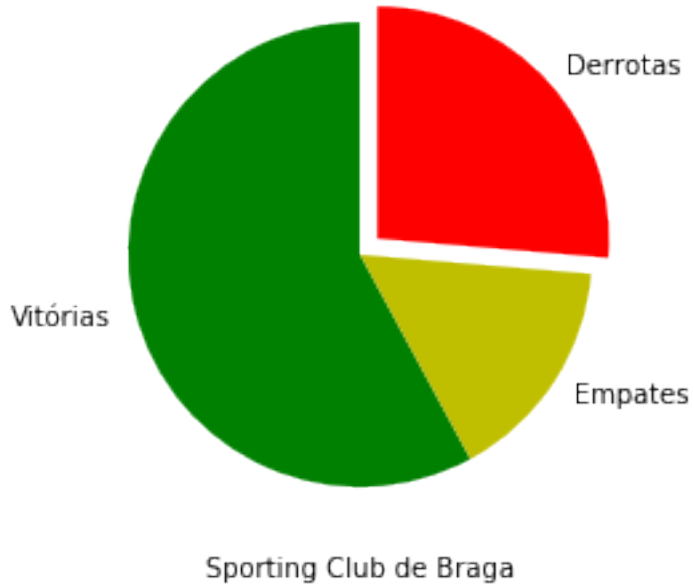

[14]:
```
resultados = 'Vitórias', 'Empates', 'Derrotas'
jogos = [ 11, 3, 5 ]
explode = (0, 0, 0.1)
colors = ['g','y','r']
plt.xlabel("Sporting Club de Braga", verticalalignment='top')
plt.pie(jogos, explode=explode, labels=resultados, colors=colors, startangle=90.
↪0)
plt.show()
```

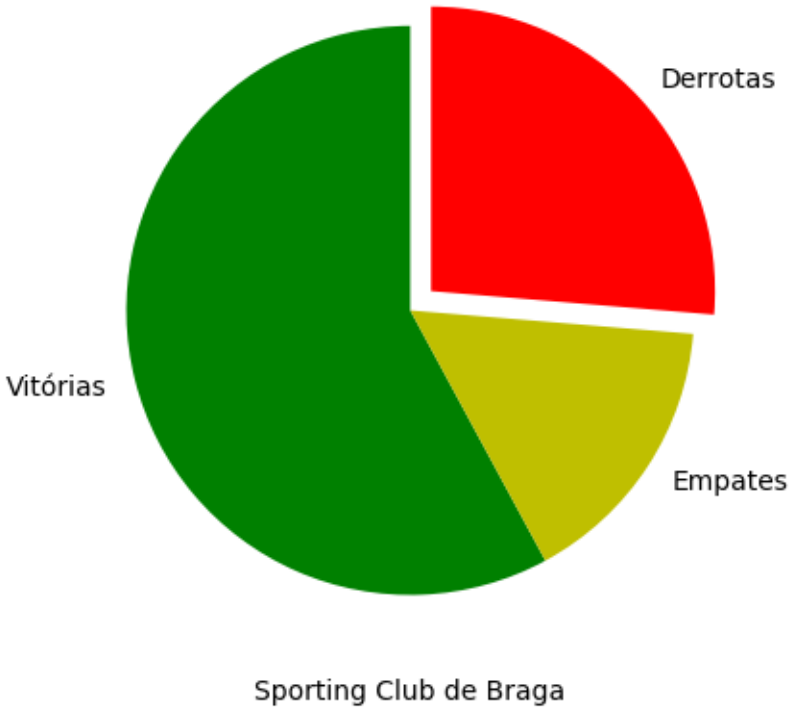

1.1.10 Acrescentar alguma matemática

Olhe para o gráfico da mortalidade apresentado. A taxa de mortalidade está a crescer ou a diminuir? Qual será o valor em 2019?

A estatística pode dar uma ajuda e o módulo `scipy.stats` também, pois permite-nos calcular uma regressão linear a partir dos dados que já temos em relação à taxa de mortalidade bruta.

Nota: se não tem o módulo `scipy` instalado, instale-o com o `pip` ou com o `conda` do Anaconda. No Linux, poderá fazer: `sudo pip3 install scipy`, para instalar este módulo.

Sendo `x` e `y`:

```
x = população.Ano
y = população.Mortalidade
```

Podemos calcular a regressão linear da seguinte forma:

```
stats = linregress(x, y)

m = stats.slope
b = stats.intercept
```

em que os coeficientes `m` e `b` são os habituais para uma linha `y = mx + b`. Em particular, o coeficiente `m` dá-nos o declive, que nos diz se esta taxa tem crescido, está estável ou tem diminuído.

Sabendo os coeficientes `m` e `b`, usando a equação `y = mx + b`, podemos estimar a taxa de moralidade em 2019.

[15]:
```
from scipy.stats import linregress
stats = linregress(x, y)

m = stats.slope
b = stats.intercept
coef = stats.rvalue

taxa_2019 = m * 2019 + b
print( "Taxa de Mortalidade Bruta estimada para 2019: {:0.1f}".format(␣
 ↪taxa_2019 ) )
print( "O coeficiente quadrado desta relação é: {:0.3f}".format(coef**2) )
```

```
Taxa de Mortalidade Bruta estimada para 2019: 11.1
O coeficiente quadrado desta relação é: 0.897
```

A mesma regressão se poderia calcular para a natalidade:

[16]:
```
stats = linregress(população.Ano, população.Natalidade)

m_n = stats.slope
b_n = stats.intercept
```

Nota:

Para a taxa bruta de natalidade (para este conjunto de anos), não é possível estabelecer uma relação tão boa como na mortalidade. Isso é muito fácil de ver com um outro resultado do cálculo da regressão linear (o coeficiente de determinação):

Para a mortalidade:

```
stats = linregress(x, y)
coef = stats.rvalue
print(coef**2)
0.8974737775151429
```

Para a natalidade:

```
stats = linregress(população.Ano, população.Natalidade)
coef = stats.rvalue
print(coef**2)
0.06238859180035636
```

O coeficiente quadrado da taxa de mortalidade é perto de 1, o que significa que há uma boa relação. Já o coeficiente quadrado da taxa de natalidade é perto de 0. Significa que não há uma relação linear entre o ano e a taxa bruta de natalidade.

1.1.11 Gráfico com duas séries

No gráfico seguinte, juntamos duas visualizações. O eixo dos `x` é o mesmo. No eixo dos `y`, mostramos os valores da taxa de mortalidade e a relação linear entre o ano e a taxa de mortalidade bruta. A regressão linear está desenhada a vermelho, para se ver melhor.

[17]:
```
plt.scatter( x, y, color="black")
plt.plot(x, m * x + b, color="red")
```

[17]:
```
[<matplotlib.lines.Line2D at 0x7f06d0600bd0>]
```

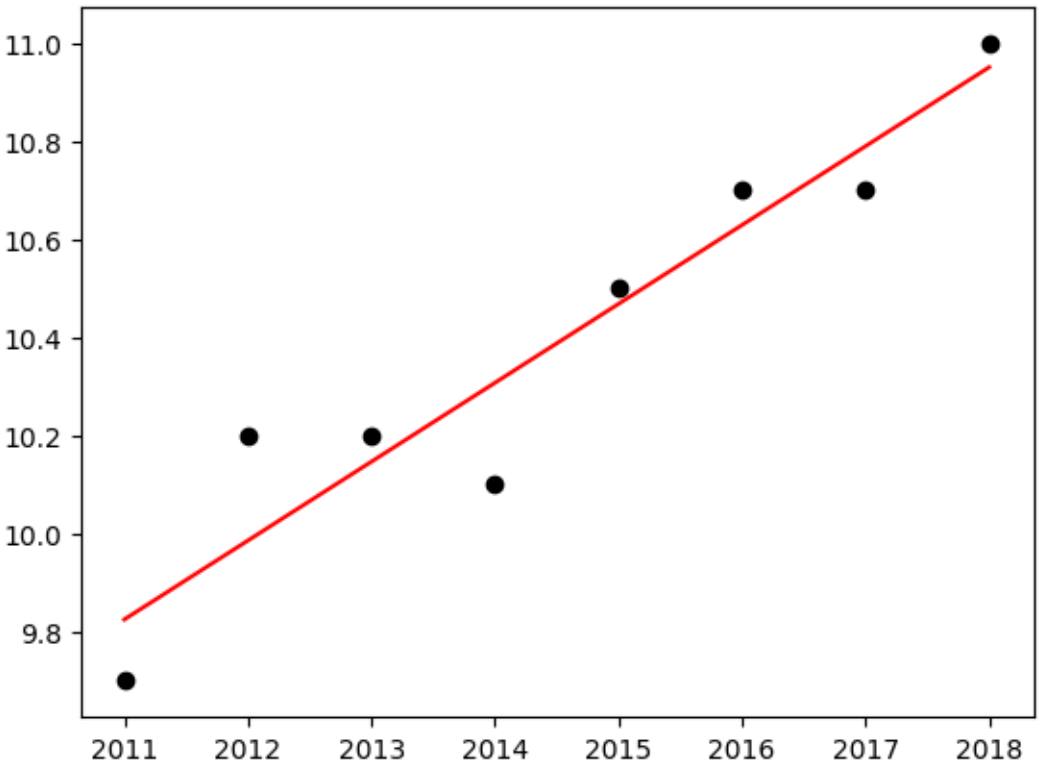

O gráfico apresentado, permite ver uma tendência clara de aumento da Taxa Bruta de Mortalidade.

Vamos melhorar o gráfico anterior, com um título em cada um dos eixos e com uma grelha.

[18]:
```
plt.scatter( x, y, color="black")
plt.plot(x, m * x + b, color="red")

plt.xlabel("Ano")
plt.ylabel("por 1000 hab.")
plt.title("Taxa Bruta de Mortalidade\nem Portugal")
plt.grid()
```

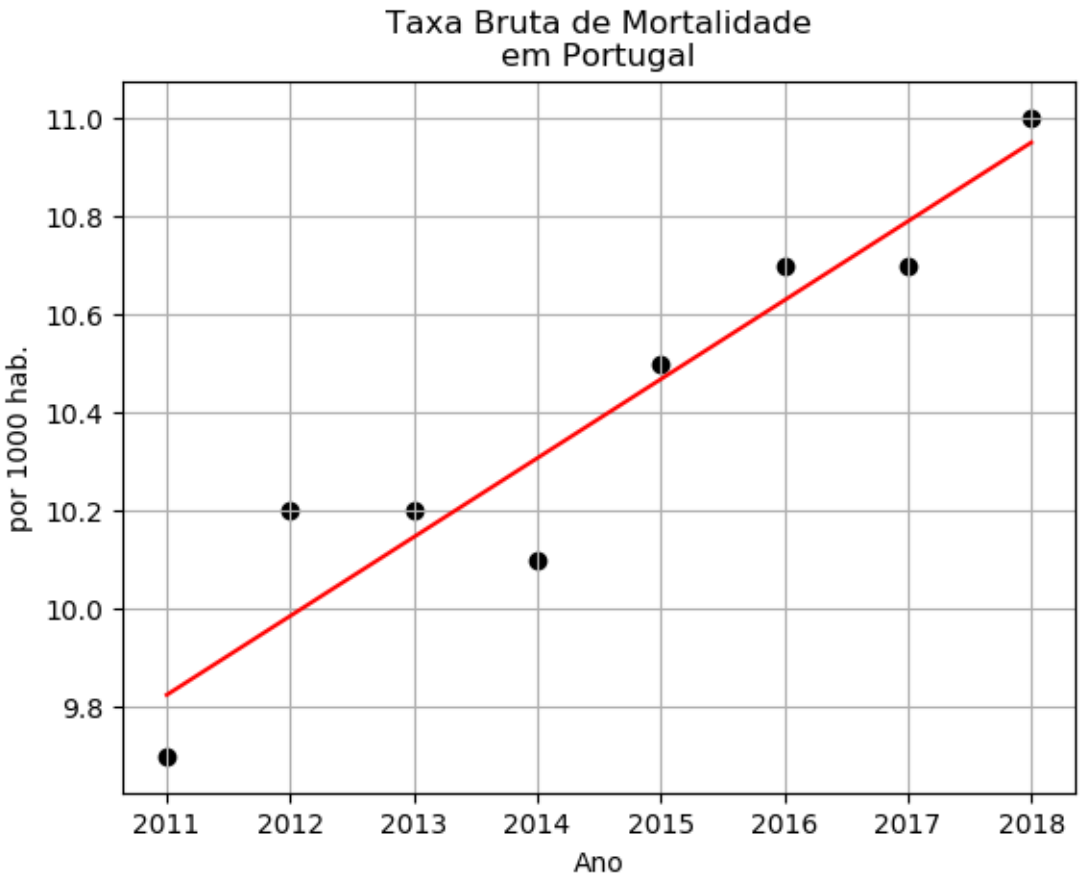

1.1.12 Compor gráficos

No exemplo seguinte, vamos colocar na mesma figura dois gráficos. Vamos ter dois subgráficos, dispostos numa linha, com duas colunas.

Repare que se usa o método `plt.subplot()` com três argumentos: os dois primeiros referm-se à geometria dos subgráficos: 1 linha, 2 colunas; o último (1 ou 2), refere-se ao índice do gráfico que vou desenhar.

[19]:
```
plt.subplot(1, 2, 1)
plt.scatter( população.Ano, população.Natalidade, color="green")
plt.subplot(1, 2, 2)
plt.scatter( população.Ano, população.Mortalidade, color="black")
```

[19]:
```
<matplotlib.collections.PathCollection at 0x7f06b3419410>
```

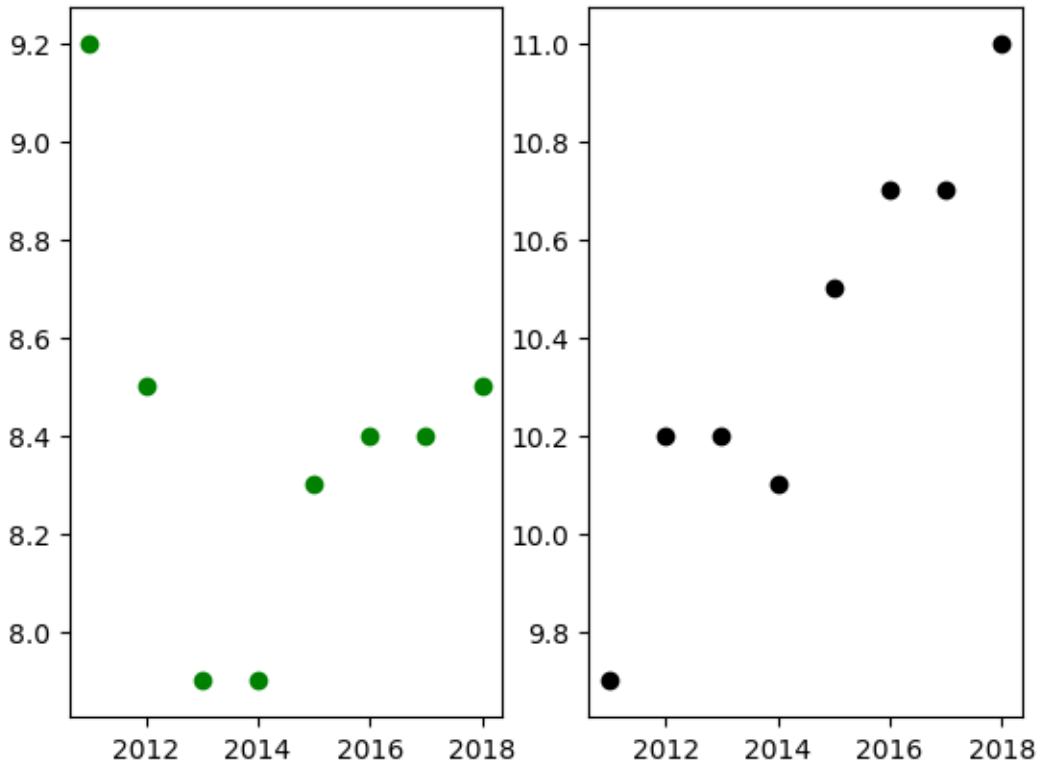

De forma análoga, se se quiserem juntar quatro gráficos na mesma figura, podemos criar uma geometria de duas linhas por duas colunas (2x2), como é ilustrado na figura seguinte:

[20]:
```
plt.subplot(2, 2, 1)
plt.scatter( população.Ano, população.Natalidade, color="green")
plt.subplot(2, 2, 2)
plt.plot(x, m_n * x + b_n, color="brown")
plt.subplot(2, 2, 3)
plt.scatter( população.Ano, população.Mortalidade, color="black")
plt.subplot(2, 2, 4)
plt.plot(x, m * x + b, color="red")
```

[20]:
```
[<matplotlib.lines.Line2D at 0x7f06b3260750>]
```

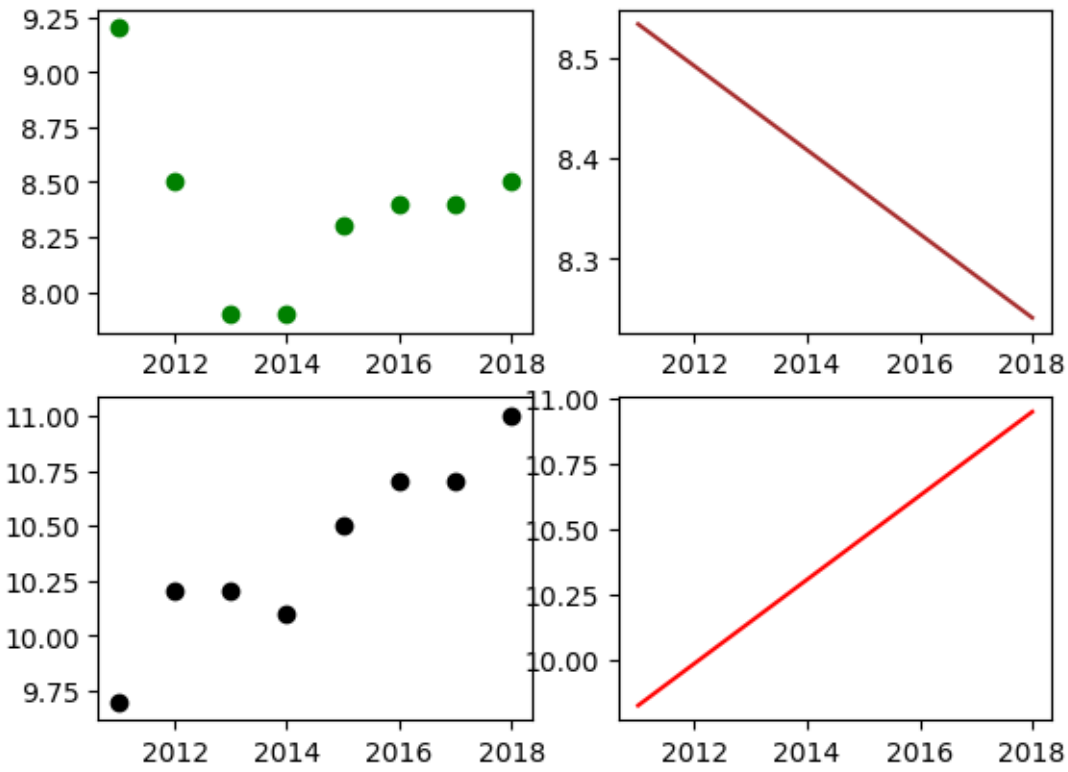

Compor o mesmo gráfico, de uma forma diferente O `pyplot` existe a noção de figura atual. Ou seja, quando estamos a preparar um gráfico, estamos a configurar a figura atual. No Jupyter, em cada célula criamos e modificamos a figura dessa célula. Na célula seguinte, a figura é outra e assim sucessivamente. Por isso, no Jupyter não nos precisamos de preocupar muito com este conceito, se só estamos a produzir gráficos simples.

Contudo, torna-se mais claro dar nomes aos diferentes objectos que compõem o gráfico.

Vamos escrever mais duas formas alternativas de compor o mesmo gráfico.

O gráfico anterior pode ser definido da seguinte forma:

[21]:
```
fig = plt.figure()
ax_natal = fig.add_subplot(2, 2, 1)
ax_natal.scatter( população.Ano, população.Natalidade, color="green")

ax_regressao_n = fig.add_subplot(2, 2, 2)
ax_regressao_n.plot(x, m_n * x + b_n, color="brown")

ax_mortal = fig.add_subplot(2, 2, 3)
ax_mortal.scatter( população.Ano, população.Mortalidade, color="black")

ax_regressao = fig.add_subplot(2, 2, 4)
```

```
ax_regressao.plot(x, m * x + b, color="red")
```

[21]:
```
[<matplotlib.lines.Line2D at 0x7f06b30e1a90>]
```

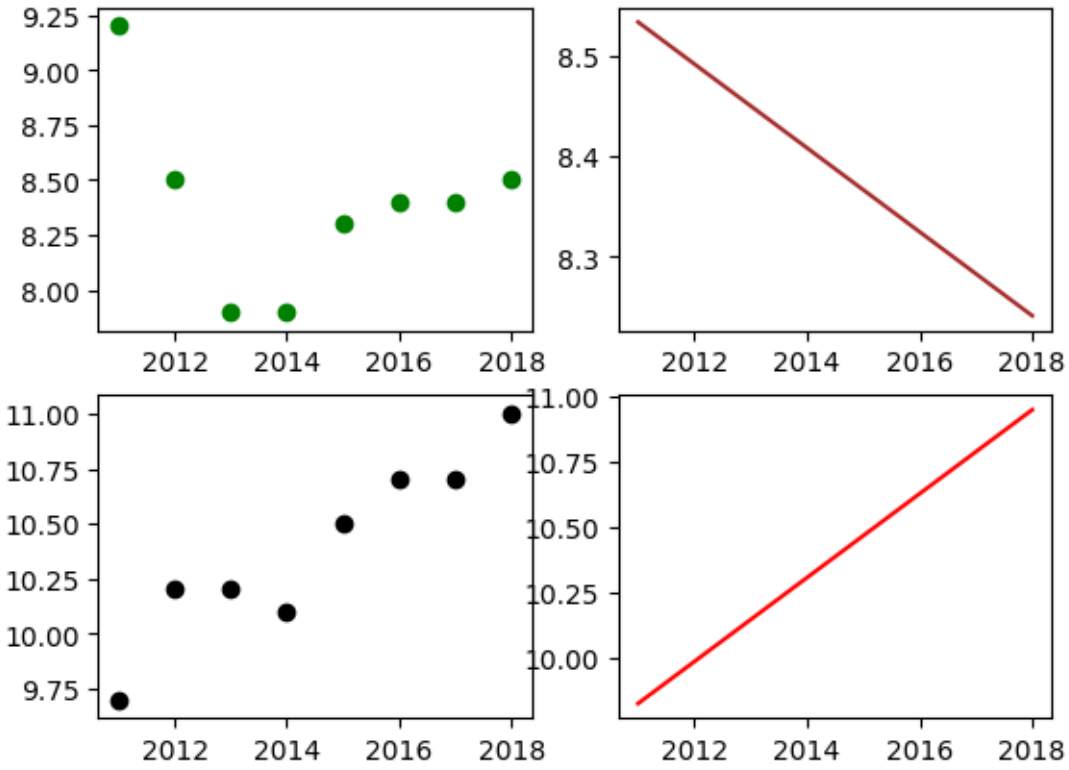

Esta notação torna mais fácil e mais clara a manipulação dos diferentes objectos da figura. Passa a ter objectos que representam a figura em si (`fig`), e cada um dos eixos (`ax_natal`, `ax_regressao_n`, `ax_mortal`, `ax_regressao`).

À medida que for construíndo gráficos mais complexos, verá que esta notação torna mais claro o manuseamento das diferentes componentes do gráfico.

Podemos usar uma outra forma ainda mais compacta, que cria os mesmos objectos, e que é a forma mais indicada.

Vamos usar esta preferencialmente esta forma, para os gráficos mais complexos.

[22]:
```
fig = plt.figure()
fig, ((ax_natal, ax_regressao_n), (ax_mortal, ax_regressao)) = plt.subplots(2,␣
↪2)
ax_natal.scatter( população.Ano, população.Natalidade, color="green")
ax_regressao_n.plot(x, m_n * x + b_n, color="brown")
ax_mortal.scatter( população.Ano, população.Mortalidade, color="black")
ax_regressao.plot(x, m * x + b, color="red")
```

[22]: [<matplotlib.lines.Line2D at 0x7f06b2fbae90>]

<Figure size 640x480 with 0 Axes>

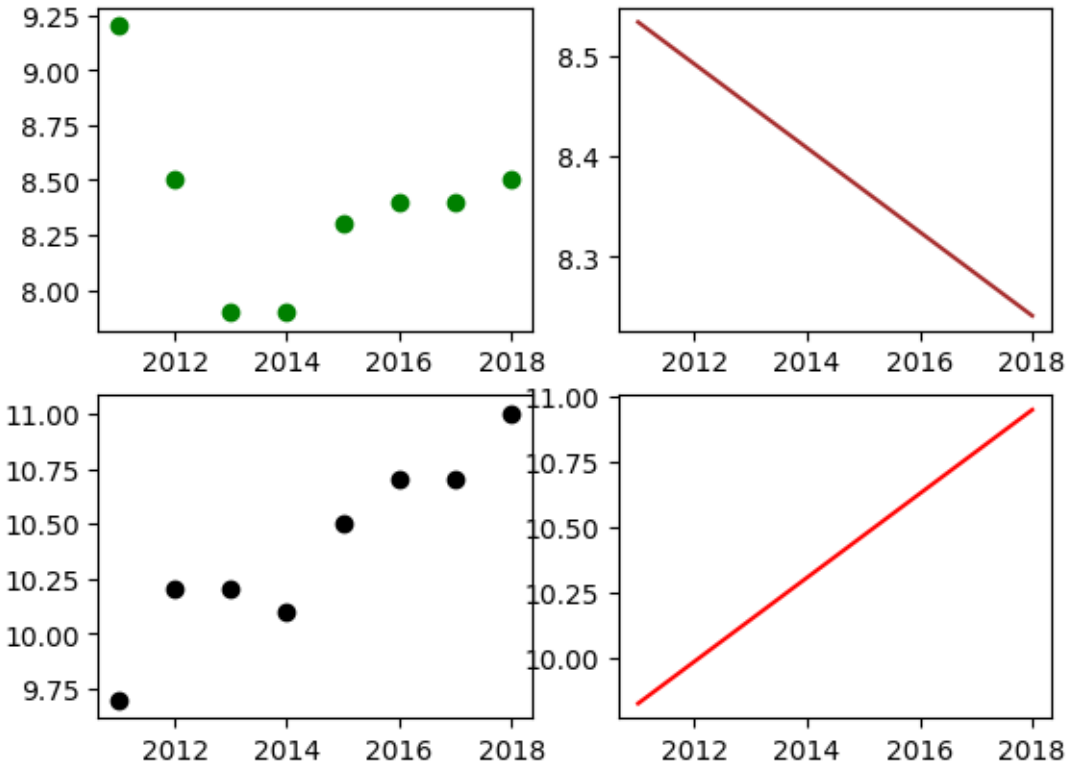

1.1.13 Alargar o tamanho do gráfico

Pode-se alterar as propriedades da figura que é criada, quando nada é dito. No exemplo seguinte, vamos explicitamente criar uma figura com o dobro da largura, para acomodar melhor os dois gráficos lado a lado.

As dimensões predefinidas são: 6.4" por 4.8" polegadas (sendo 1" igual a 25.4 mm). Ou seja, em mm, um gráfico tem as dimensões 162.56 mm de largura por 121.92 mm de altura.

Vamos duplicar a largura predefinida, para 12.8".

[23]:
```
fig, (ax_natal, ax_mortal) = plt.subplots(1, 2, figsize=( 12.8, 4.8))

ax_natal.scatter( população.Ano, população.Natalidade, color="green")
ax_mortal.scatter( população.Ano, população.Mortalidade, color="black")
```

[23]: <matplotlib.collections.PathCollection at 0x7f06d0668d50>

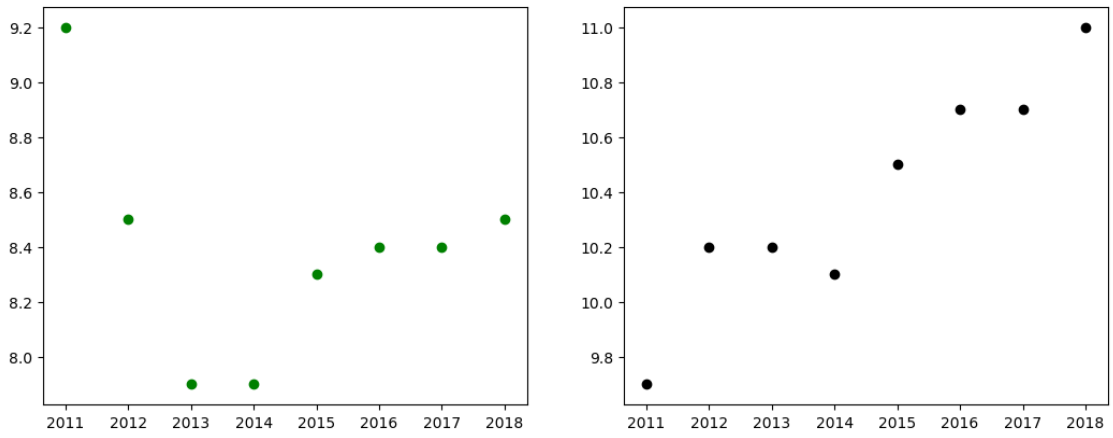

1.1.14 Partilhar eixos

Repare que até aqui temos juntado gráficos na mesma figura, mas sempre independentes. Neste caso, pode-se melhorar a informação passada pelos gráficos, usando os mesmos valores em y. Ou seja, tornando o eixo dos y comum aos dois gráficos da figura.

[24]:
```
fig, (ax_natal, ax_mortal) = plt.subplots(1, 2, sharey=True)

ax_natal.scatter( população.Ano, população.Natalidade, color="green")
ax_mortal.scatter( população.Ano, população.Mortalidade, color="black")
```

[24]:
```
<matplotlib.collections.PathCollection at 0x7f06b2ea67d0>
```

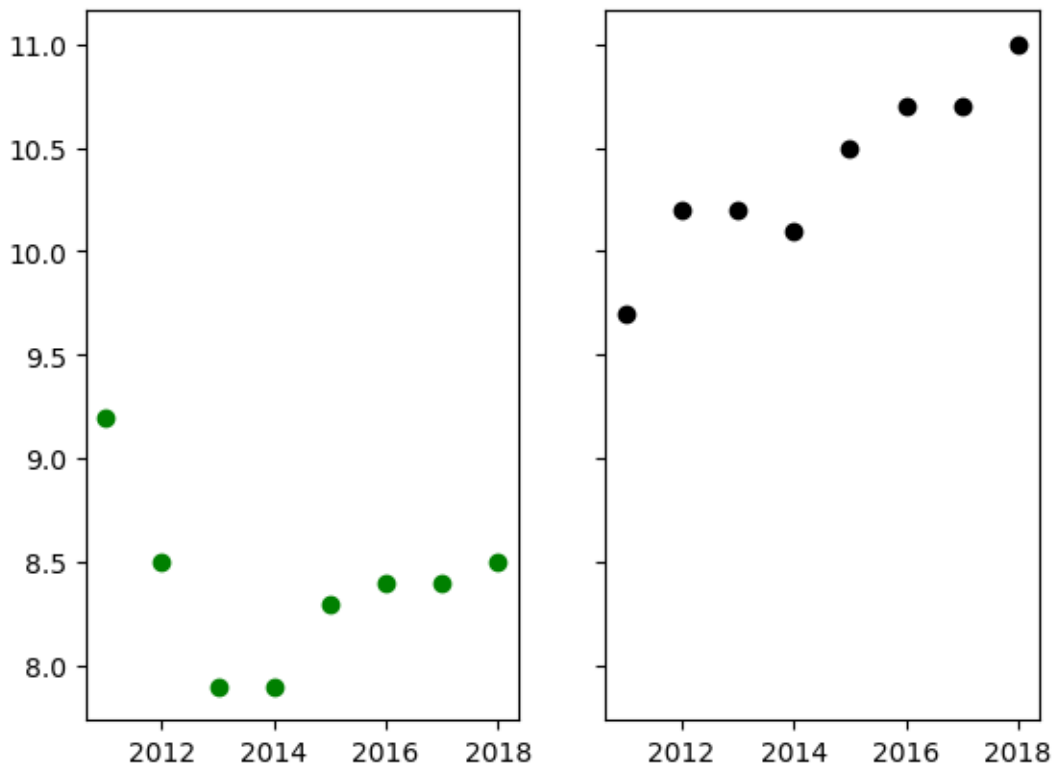

1.1.15 Gráficos 3D

Nesta introdução não se abordam os gráficos 3D, mas fica desde já a saber que esta biblioteca permite criar gráficos 3D.

[25]:
```
from mpl_toolkits.mplot3d import Axes3D

fig = plt.figure()
ax = plt.axes(projection='3d')

plt.yticks( [0, 1], [ '', 'Natalidade', 'Mortalidade' ] )

ax.bar(população.Ano, população.Natalidade, zs=1, zdir='y', color='r', alpha=0.
↪8)
ax.bar(população.Ano, população.Mortalidade, zs=2, zdir='y', color='b', alpha=0.
↪8)
```

[25]:
```
<BarContainer object of 8 artists>
```

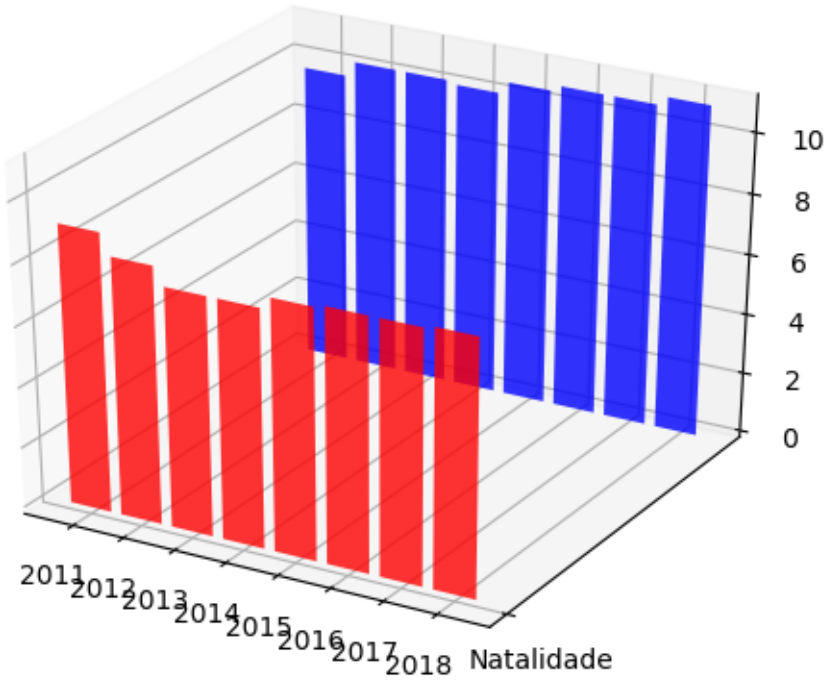

1.1.16 Gráficos interativos

O comportamenteo padrão do Jupyter é incluir os gráficos `inline`, como temos visto até aqui.

Pode-se alterar esse comportamento com uma instrução mágica (instruções começadas por %):

```
%matplotlib notebook
```

[26]:
```
%matplotlib notebook
fig, (ax_natal, ax_mortal) = plt.subplots(1, 2, sharey=True, num="Gráfico␣
↪interativo")

ax_natal.scatter( população.Ano, população.Natalidade, color="green")
ax_mortal.scatter( população.Ano, população.Mortalidade, color="black")
ax_mortal.plot(população.Ano, m * x + b, color="red")
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.HTML object>
```

[26]:
```
[<matplotlib.lines.Line2D at 0x7f06b2d63a50>]
```

Ao definir gráficos interativos, são acrescentadas ferramentas que lhe permitem interagir com o gráfico.

Experimente, por exemplo, com a ferramenta **Pan**. Pode arrastar o conteúdo do gráfico e os eixos são atualizados automaticamente.

1.1.17 Exercício

Para aprender a trabalhar com o **pan** e o **zoom** interativo, diga em que dia(s) se verificaram registos irregulares de cados confirmados de COVID-19 em Portugal.

O gráfico é obtido com as seguintes instruções:

[27]:
```
pandemia = pandas.read_csv('https://raw.githubusercontent.com/jgrocha/covid-pt/
↪master/situacao_epidemiologica.csv')
confirmados = pandemia.sort_values(by=['data_relatorio'])[['data_relatorio',␣
↪'confirmados']]

%matplotlib notebook
fig, ax = plt.subplots()
ax.plot(confirmados.data_relatorio, confirmados.confirmados)
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.HTML object>
```

[27]:
```
[<matplotlib.lines.Line2D at 0x7f06b1007cd0>]
```

1.1.18 Resposta

1.1.19 Exercício (resolvido)

Vamos mostrar as diferenças entre a mortalidade, por escalão e por sexo, para os dados COVID-19 disponibilizados pela DGS.

[31]:
```
pandemia.columns
```

[31]:
```
Index(['id', 'url', 'data_relatorio', 'suspeitos', 'confirmados',
       'nao_confirmados', 'aguarda_resultados', 'recuperados', 'obitos',
       'em_vigilancia', 'confirmados_masculino_0_9',
       'confirmados_masculino_10_19', 'confirmados_masculino_20_29',
       'confirmados_masculino_30_39', 'confirmados_masculino_40_49',
       'confirmados_masculino_50_59', 'confirmados_masculino_60_69',
       'confirmados_masculino_70_79', 'confirmados_masculino_80_sup',
       'confirmados_feminino_0_9', 'confirmados_feminino_10_19',
       'confirmados_feminino_20_29', 'confirmados_feminino_30_39',
       'confirmados_feminino_40_49', 'confirmados_feminino_50_59',
       'confirmados_feminino_60_69', 'confirmados_feminino_70_79',
       'confirmados_feminino_80_sup', 'importados', 'internados',
       'internados_uci', 'sintoma_febre', 'sintoma_tosse',
       'sintoma_respiratoria', 'sintoma_cefaleia', 'sintoma_dores',
```

```
       'sintoma_fraqueza', 'obitos_masculino_0_9', 'obitos_masculino_10_19',
       'obitos_masculino_20_29', 'obitos_masculino_30_39',
       'obitos_masculino_40_49', 'obitos_masculino_50_59',
       'obitos_masculino_60_69', 'obitos_masculino_70_79',
       'obitos_masculino_80_sup', 'obitos_feminino_0_9',
       'obitos_feminino_10_19', 'obitos_feminino_20_29',
       'obitos_feminino_30_39', 'obitos_feminino_40_49',
       'obitos_feminino_50_59', 'obitos_feminino_60_69',
       'obitos_feminino_70_79', 'obitos_feminino_80_sup'],
      dtype='object')
```

[29]:
```
# pandemia
recente = pandemia.sort_values(by=['data_relatorio'], ascending=False).
 ↪head(1)['data_relatorio'].values
recente[0]
feminino = pandemia.filter(regex=("obitos_feminino"))[ pandemia.data_relatorio␣
 ↪== recente[0] ].values
masculino = pandemia.filter(regex=("obitos_masculino"))[ pandemia.
 ↪data_relatorio == recente[0] ].values
# obitos_feminino_0_9          obitos_feminino_10_19␣
 ↪         obitos_feminino_20_29          obitos_feminino_30_39␣
 ↪         obitos_feminino_40_49          obitos_feminino_50_59␣
 ↪         obitos_feminino_60_69          obitos_feminino_70_79␣
 ↪         obitos_feminino_80_sup
obitos_feminino = feminino[0]
obitos_masculino = masculino[0]
escalões = '0-9', '10-19', '20-29', '30-38', '40-49', '50-59', '60-69',␣
 ↪'70-79', '80-sup'

fig, (ax_masculino, ax_feminino) = plt.subplots(ncols=2, sharey=True)
ax_masculino.barh(escalões, obitos_masculino, align='center', color='blue')
ax_feminino.barh(escalões, obitos_feminino, align='center', color='pink')

ax_masculino.set_xlim(ax_feminino.get_xlim())
ax_masculino.invert_xaxis()
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.HTML object>
```

1.1.20 Exercício

Faça um gráfico similar ao anterior para os casos confirmados, por escalão etário e por sexo, para a data mais recente.

[32]:
```
# pandemia
recente = pandemia.sort_values(by=['data_relatorio'], ascending=False).
 ↪head(1)['data_relatorio'].values
recente[0]
feminino = pandemia.filter(regex=("confirmados_feminino"))[ pandemia.
 ↪data_relatorio == recente[0] ].values
masculino = pandemia.filter(regex=("confirmados_masculino"))[ pandemia.
 ↪data_relatorio == recente[0] ].values
# obitos_feminino_0_9          obitos_feminino_10_19␣
 ↪         obitos_feminino_20_29          obitos_feminino_30_39␣
 ↪         obitos_feminino_40_49          obitos_feminino_50_59␣
 ↪         obitos_feminino_60_69          obitos_feminino_70_79␣
 ↪         obitos_feminino_80_sup
obitos_feminino = feminino[0]
obitos_masculino = masculino[0]
escalões = '0-9', '10-19', '20-29', '30-38', '40-49', '50-59', '60-69',␣
 ↪'70-79', '80-sup'

fig, (ax_masculino, ax_feminino) = plt.subplots(ncols=2, sharey=True)
ax_masculino.barh(escalões, obitos_masculino, align='center', color='blue')
ax_feminino.barh(escalões, obitos_feminino, align='center', color='pink')

ax_masculino.set_xlim(ax_feminino.get_xlim())
ax_masculino.invert_xaxis()
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.HTML object>
```

1.1.21 Exercício

Faça um gráfico de barras na horizontal, como os anteriores, para o total de casos confirmados ao longo do tempo. No eixo dos Y devem aparecer as datas, da mais recente para a mais antiga.

[ ]:
```

```